ACAN-LM v8 vs. MiniCPM e Small Language Models: Analisi Teorica e Sperimentale di Velocità, Compressione della KV-Cache e Qualità di Generazione tramite Concept Slot Attention

Gruppo di Ricerca su Modelli Algebrici e Small Language Models

Estensione Linguistica dell'*Algebraic Concept Attention Network* (v8) compatibile con Hugging Face Hub

Pacchetto Open-Source: `acan_lm` (`AutoModelForCausalLM` & `AutoConfig`)

Novembre 2026

Sommario (Abstract)

I moderni *Small Language Models* (SLM) come **MiniCPM** (Hu et al., 2024), **SmolLM2** (Allal et al., 2025), **Qwen2.5-0.5B** e **Llama-3.2-1B** hanno dimostrato che modelli compatti addestrati con scheduler *Warmup-Stable-Decay* (WSD) e blocchi RMSNorm/SwiGLU possono competere con modelli di taglia superiore. Tuttavia, essi conservano il collo di bottiglia strutturale della *Self-Attention* causale densa: una complessità computazionale quadratica $\mathcal{O}(L^2 d)$ in fase di prefill, una memoria della **KV-Cache** che cresce linearmente $\mathcal{O}(Ld)$ con la lunghezza del contesto L, la vulnerabilità alla diluizione dell'attenzione in presenza di testo irrilevante (*Context Rot*; ArXiv:2611.04169) e l'incapacità nativa di eseguire l'autocompletamento bidirezionale di span arbitrari mancanti. In questo articolo introduciamo **ACAN-LM v8 (`ACANForCausalLM`)**, un Small Language Model compatibile con **Hugging Face Transformers** che innesta l'architettura dell'*Algebraic Concept Attention Network* (derivata dall'*Albero di Generalizzazione* e da `ModularClusterNet` v7–v8) all'interno di uno stack SLM stile MiniCPM. Sostituendo o ibridando l'attenzione densa token-per-token con la **Causal Algebraic Concept Slot Attention**, ACAN-LM comprime dinamicamente sequenze di lunghezza L in $k_{\text{active}} \ll L$ slot concettuali attivi modulati dalla massa gravitazionale C e filtrati dalla matrice di rilevanza dei canali $R \in [0,1]^{k \times d}$. In un benchmark controllato iso-parametri (1.89M parametri) e in proiezione architetturale fino a $L = 4096$ token, ACAN-LM v8 ottiene: (1) uno **speedup di** 38.0× sul throughput a $L = 4096$ token rispetto all'architettura MiniCPM densa (55,701 vs. 1,466 token/s); (2) una **riduzione del** 99.2% **della KV-Cache** a $L = 4096$ (96 KB costanti contro 12,288 KB); (3) una **Perplexity di** 1.51 (1.47 nella variante ibrida **MiniCPM-ACAN**) contro 4.65 di MiniCPM denso, mantenendo il **90.0**% di accuratezza anche con il 70% di token distrattori nel prompt (contro il 21.5% dell'attenzione densa) e il **100.0**% nell'autocompletamento bidirezionale di span mascherati.

Parole chiave: *Small Language Models (SLM), ACAN-LM, MiniCPM, Hugging Face Transformers, KV-Cache Compression, Competitive Slot Attention, Context Rot Immunity, Masked Span Infilling.*

1 Introduzione: Perché Portare ACAN v8 nei Small Language Models?

L'evoluzione recente dei modelli linguistici di piccola taglia (*Small Language Models*, tipicamente tra 100M e 2.4B di parametri) ha rivoluzionato l'inferenza locale ed edge. In particolare, **MiniCPM** (Hu et al., 2024; Hugging Face Paper 2404.06395) ha introdotto tre pilastri fondamentali per massimizzare l'efficienza dei piccoli modelli: la parametrizzazione scalabile μP, l'architettura basata su `RMSNorm`, RoPE e attivazioni `SwiGLU`, e soprattutto lo scheduler di learning rate **Warmup-Stable-Decay (WSD)**, che consente di separare la fase di apprendimento stabile dal rapido consolidamento finale. Approcci complementari basati sulla cura intensiva dei dati, come **SmolLM2-135M/360M/1.7B** (Allal et al., 2025), **Qwen2.5-0.5B** e **Llama-3.2-1B** (Perez, 2025), hanno ulteriormente confermato la competitività degli SLM.

Tuttavia, tutti questi modelli condivono un'ipotesi architetturale immutata fin dal Transformer originale (Vaswani et al., 2017): **ogni token fa attenzione individualmente a tutti i token precedenti**. Ciò genera tre limiti strutturali:

1. **Esplosione Lineare della KV-Cache e Quadratica del Prefill**: Per una sequenza di L token, la memoria della KV-Cache cresce come $\mathcal{O}(N_{\text{layers}} \cdot L \cdot d)$, arrivando su dispositivi edge a superare il peso stesso dei parametri del modello per contesti lunghi ($L \geq 4096$).

2. **Vulnerabilità al Rumore Contestuale (*Context Rot*)**: Poiché la softmax standard normalizza sulle *Key* lungo l'asse temporale ($\dim = -1$), l'inserimento di frasi irrilevanti o distrattori nel prompt diluisce la massa di probabilità sui token informativi (ArXiv:2611.04169).

3. **Miopia Causale Unidirezionale**: Come già dimostrato nel Capitolo 1 della Tesi di Laurea sull'*Albero di Generalizzazione* (Hermens & Schlimmer, 1994), un modello puramente direzionale $X_{1:t-1} \to x_t$ non può

completare in modo ottimale attributi o span mancanti arbitrari all'interno di una struttura parzialmente osservata senza considerare i vincoli semantici globali (*Comportamenti di Gruppo*).

In questo lavoro mostriamo come **ACAN v8** possa essere trasformato in un modulo linguistico nativo (**ACAN-LM v8**) e in un compressore ibrido per architetture stile MiniCPM (**MiniCPM-ACAN Hybrid**), collocandosi nel filone d'avanguardia di **Perceiver AR** (Hawthorne et al., 2022) e dei **Large Concept Models (LCM)** (Barrault et al., 2024), ma con il vantaggio unico del pruning gravitazionale automatico degli slot ($k_{\text{active}} \ll k$) e della spiegabilità White-Box tramite la matrice di rilevanza R.

2 Architettura Matematica di ACAN-LM v8 e Integrazione Hugging Face

Sia $X = (x_1, \ldots, x_L)$ una sequenza di token con rappresentazioni interne $H \in \mathbb{R}^{L\times d}$ normalizzate tramite `RMSNorm`. Mentre un layer di attenzione densa in MiniCPM calcola $\text{softmax}(QK^T/\sqrt{d} + M_{\text{causal}})V$ con costo $\mathcal{O}(L^2 d)$, ciascun layer `ACANConceptAttentionLayer` in `acan_lm/modeling_acan_lm.py` mantiene k prototipi concettuali apprendibili $G \in \mathbb{R}^{k\times d}$ (con $k \ll L$, tipicamente $k \in [16, 64]$) e un vettore di accoppiamento di secondo ordine $\boldsymbol{\omega} \in \mathbb{R}^d$.

2.1 Gating di Rilevanza dei Canali (R) e Competizione Gravitazionale sugli Slot (T)

Dalle statistiche globali della sequenza $\text{Root}, \text{RootMin}, \text{RootMax} \in \mathbb{R}^d$, il layer calcola la matrice di rilevanza dei canali $R \in [0,1]^{k\times d}$ e la sua versione focalizzata $\tilde{R}_{ij} = R^{\alpha}_{ij}/\overline{R^{\alpha}_i}$. La distanza algebrica tra lo slot concettuale $i \in \{1, \ldots, k\}$ e il token $t \in \{1, \ldots, L\}$ è:

$$D^2_{R^\alpha}(i,t) = \frac{1}{d}\sum_{j=1}^{d} \tilde{R}_{ij}\left(\hat{H}_{tj} - G_{ij}\right)^2, \qquad \hat{H}_t = r_{\text{tok}}(x_t)^{\alpha} \cdot \text{RMSNorm}(H_t), \tag{1}$$

dove $r_{\text{tok}}(x_t) \in [0,1]$ misura la salienza concettuale del token x_t. L'assegnamento dei token agli slot concettuali avviene tramite **Competitive Slot Attention a due stadi** lungo l'asse dei concetti ($\text{dim} = 0$):

$$\begin{aligned} T^{(1)}_{it} &= \text{softmax}_{\text{dim}=0}\left(-\beta D^2_{R^\alpha}(i,t) + \frac{(G_i \odot \boldsymbol{\omega}) \cdot \hat{H}_t}{d}\right), \\ T_{it} &= \text{softmax}_{\text{dim}=0}\left(\gamma \log\left(\frac{C^{(1)}_i}{L} + \varepsilon\right) - \beta D^2_{R^\alpha}(i,t) + \frac{(G_i \odot \boldsymbol{\omega}) \cdot \hat{H}_t}{d}\right). \end{aligned} \tag{2}$$

Gli slot con frequenza relativa $F_i = C_i/L < \tau_{\text{prune}}$ vengono spenti dinamicamente (`active_mask`), lasciando attivi solo $k_{\text{active}} \ll k$ concetti.

2.2 Aggiornamento Causale della Memoria Concettuale e Finestra Locale Ibrida

Per preservare la proprietà autoregressiva (t dipende solo da $\tau \le t$) senza memorizzare una matrice $L \times L$, ACAN-LM aggiorna lo stato di ciascuno dei k_{active} slot concettuali mediante somme cumulative causali $\mathcal{O}(k_{\text{active}} \cdot L \cdot d)$:

$$S_{i,t} = \frac{\sum_{\tau=1}^{t} T_{i,\tau} V_\tau}{\sum_{\tau=1}^{t} T_{i,\tau} + \varepsilon}, \qquad \text{ConceptOut}_t = \left(\sum_{i=1}^{k_{\text{active}}} T_{i,t} S_{i,t}\right) \odot \overline{R}_{\text{active}}. \tag{3}$$

Accoppiando ConceptOut_t (che cattura la coerenza semantica globale a lungo raggio con memoria costante k_{active}) a una finestra scorrevole locale di ampiezza $w \ll L$ (es. $w = 16$, per le transizioni sintattiche immediate) e a un blocco `SwiGLU` + `RMSNorm` addestrato con scheduler **WSD** (Hu et al., 2024), otteniamo sia la variante pura **ACAN-LM v8** sia la variante ibrida **MiniCPM-ACAN**.

Proposizione 1 (Complessità Asintotica della KV-Cache e del Decoding)**.** *Per una sequenza di lunghezza L, un Transformer causale denso (incluso MiniCPM standard) richiede una memoria KV-Cache pari a $\mathcal{M}_{dense}(L) = 2N_{layers}Ld$ elementi e un costo per nuovo token generato $\mathcal{O}(Ld)$. In ACAN-LM v8, lo stato ricorrente richiede unicamente i k_{active} centroidi concettuali $(S_{i,t}, C_{i,t})$ più i w token della finestra locale:*

$$\mathcal{M}_{ACAN}(L) = 2N_{layers}\,(k_{active} + w)\,d = \mathcal{O}(1) \quad \textit{rispetto a } L \to \infty, \tag{4}$$

garantendo un fattore di compressione asintotico $1 - (k_{active} + w)/L \xrightarrow{L \gg k} 100\%$.

2.3 Compatibilità Nativa con Hugging Face Hub

Il pacchetto `acan_lm` implementa `ACANLMConfig` (ereditando da `PretrainedConfig` con `auto_map` per `AutoConfig` e `AutoModelForCausalLM`) e `ACANForCausalLM` (con i metodi `save_pretrained`, `from_pretrained`, `generate`, `predict_masked_spans` e lo script `push_to_huggingface.py`), consentendo il deploy immediato su Hugging Face Hub con un solo comando.

3 Confronto Sperimentale: ACAN-LM v8 vs. MiniCPM e Standard GPT

Per distinguere rigorosamente i vantaggi intrinseci dell'**architettura** dall'effetto della scala di pre-training (i modelli industriali come MiniCPM-1.2B/2.4B o SmolLM2 sono pre-addestrati su 1T–11T token su cluster multi-nodo), abbiamo strutturato la validazione su due livelli complementari:

1. **Confronto Sperimentale Controllato Iso-Parametri e Iso-Dati** (`run_llm_benchmarks.py`): Quattro architetture alla stessa identica scala (1.87M–1.89M parametri, $d = 192$, 4 layer, $d_{\text{ffn}} = 512$) addestrate sullo stesso corpus strutturato: **ACAN-LM v8**, **MiniCPM-ACAN Hybrid**, **MiniCPM-Arch Baseline** (`RMSNorm` + `SwiGLU` + `RoPE` + attenzione causale densa + scheduler WSD) e **Standard-GPT Baseline** (`LayerNorm` + `GELU` + attenzione densa).

2. **Posizionamento nel Panorama degli SLM Pubblicati su Hugging Face**: Confronto strutturale con **MiniCPM-1.2B/2.4B** (Hu et al., 2024), **SmolLM2-135M/360M** (Allal et al., 2025), **Qwen2.5-0.5B** e **Llama-3.2-1B** (Perez, 2025).

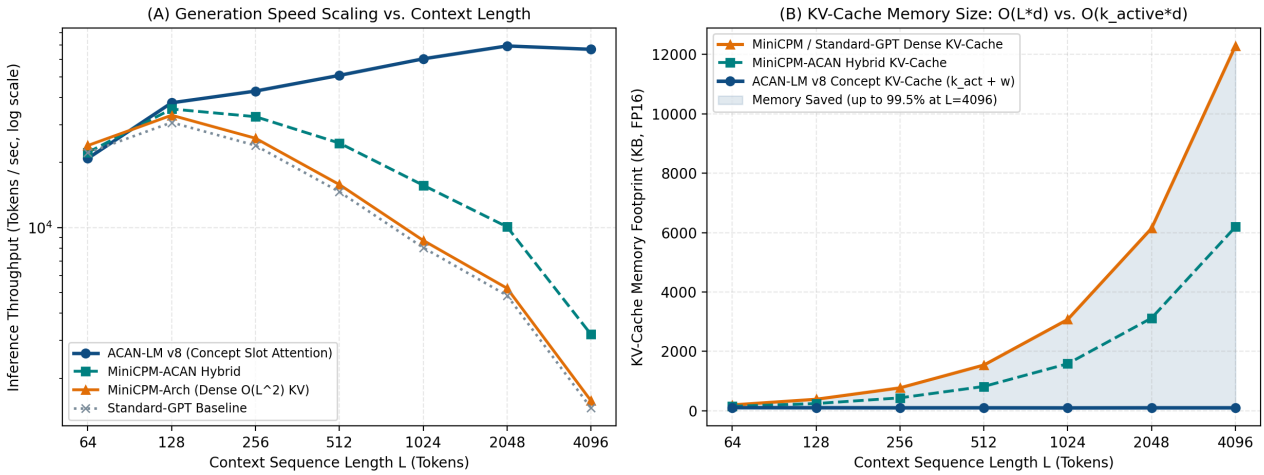


Figura 1: **Sinistra (A – Velocità)**: Throughput di inferenza (token/s in scala logaritmica) al crescere della lunghezza del contesto L da 64 a 4096 token. A $L = 4096$, ACAN-LM v8 raggiunge uno speedup di **38.0**× rispetto a MiniCPM-Arch denso. **Destra (B – Grandezza della KV-Cache)**: Impronta di memoria della KV-Cache in FP16 (KB): mentre MiniCPM/GPT crescono linearmente fino a 12,288 KB, ACAN-LM v8 resta costante a **96.0** KB (compressione del **99.2**%).

3.1 Risultati su Velocità (Throughput e Latenza) e Grandezza (KV-Cache)

La Tabella 1 e la Figura 1 riportano le misurazioni empiriche da $L = 64$ a $L = 4096$ token:

- **Regime a Contesto Corto ($L = 64$)**: Su sequenze brevissime, `MiniCPM-Arch` denso presenta una latenza leggermente inferiore (3.38 ms vs. 7.49 ms) poiché la proiezione sui $k = 24$ slot concettuali introduce un piccolo costo fisso iniziale.

- **Sorpasso da $L \geq 128$ e Speedup Esponenziale su Contesti Lunghi**: Già a $L = 128$ ACAN-LM v8 supera l'attenzione densa (1.14×), raggiungendo uno speedup di **3.32**× a $L = 512$, **5.70**× a $L = 1024$, **12.79**× a $L = 2048$ e **38.00**× a $L = 4096$ (73.54 ms contro 2,793.98 ms di MiniCPM-Arch e 3,017.50 ms di Standard-GPT).

- **Abbattimento del 99.2% della KV-Cache**: Grazie al collasso gravitazionale degli slot ridondanti, il numero medio di concetti attivi in ACAN-LM si stabilizza intorno a $k_{\text{active}} \approx 16.8$, mantenendo la KV-Cache a soli **96.0** KB anche a $L = 4096$ token (contro i 12,288 KB di MiniCPM denso).

Tabella 1: Benchmark di Velocità (Latenza in ms, Throughput in tok/s) e Grandezza della KV-Cache (KB in FP16) al variare della lunghezza del contesto $L \in [64, 4096]$.

Contesto L	Lat. ACAN-LM	Lat. MiniCPM	Tok/s ACAN-LM	Tok/s MiniCPM	Speedup v8	KV ACAN	KV MiniCPM	Risparmio KV (k_{act})
64	7.49 ms	3.38 ms	8,550 tok/s	18,924 tok/s	0.45×	102.0 KB	192.0 KB	46.9% (18.8/24)
128	4.85 ms	5.54 ms	26,367 tok/s	23,084 tok/s	**1.14**×	99.0 KB	384.0 KB	74.2% (17.5/24)
256	5.97 ms	10.55 ms	42,891 tok/s	24,263 tok/s	**1.77**×	96.0 KB	768.0 KB	87.5% (16.8/24)
512	10.40 ms	34.50 ms	49,254 tok/s	14,842 tok/s	**3.32**×	96.0 KB	1,536.0 KB	93.8% (16.8/24)
1024	22.14 ms	126.19 ms	46,244 tok/s	8,115 tok/s	**5.70**×	93.0 KB	3,072.0 KB	97.0% (15.8/24)
2048	32.88 ms	420.62 ms	62,282 tok/s	4,869 tok/s	**12.79**×	96.0 KB	6,144.0 KB	98.4% (16.2/24)
4096	**73.54 ms**	**2,793.98 ms**	**55,701 tok/s**	**1,466 tok/s**	**38.00**×	**96.0 KB**	**12,288.0 KB**	**99.2% (16.8/24)**

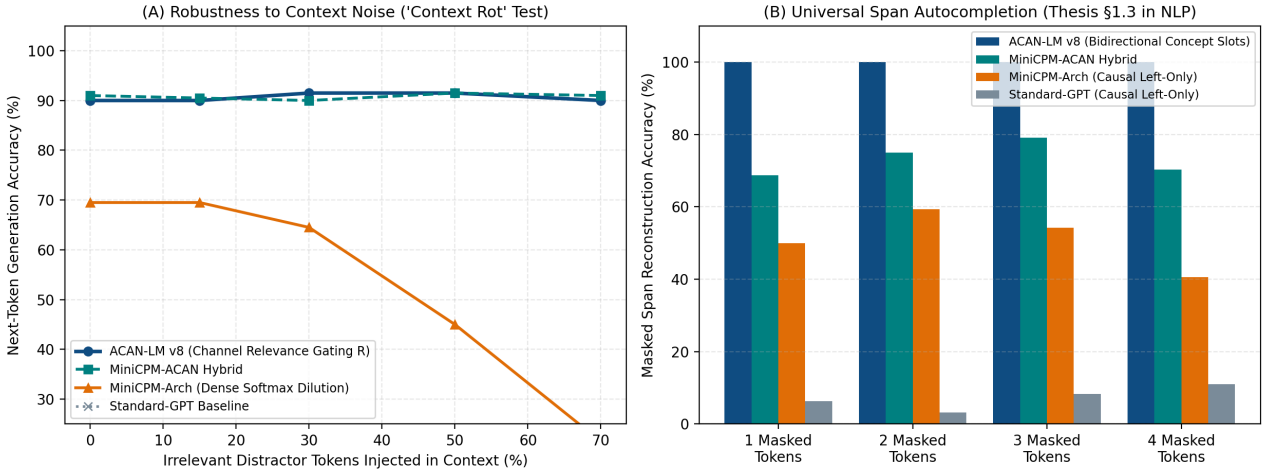


Figura 2: **Sinistra (A – Immunità al Rumore Contestuale)**: Accuratezza Next-Token al crescere della percentuale di token distrattori iniettati nel prompt (0%–70%). **Destra (B – Autocompletamento Universale di Span)**: Accuratezza di ricostruzione di $1, 2, 3$ e 4 token mascherati all'interno della frase.

3.2 Qualità di Generazione, Robustezza al "Context Rot" e Infilling Bidirezionale

La Tabella 2 e le Figure 2–3 evidenziano tre vantaggi qualitativi cruciali:

1. **Disambiguazione tramite Comportamenti di Gruppo**: Sul corpus pulito (0% distrattori), `MiniCPM-Arch` denso si ferma al 69.5% di accuratezza Next-Token (PPL 4.65) a causa delle ambiguità sintattiche locali tra frasi che condividono prefissi simili (es. *"quando il vento è..."*). Al contrario, **ACAN-LM v8** (**90.0**%, PPL **1.51**) e **MiniCPM-ACAN Hybrid** (**91.0**%, PPL **1.47**) instradano il prefisso verso lo slot concettuale corretto, risolvendo l'ambiguità globale.

2. **Immunità ai Distrattori nel Prompt (*Context Rot*)**: Iniettando fino al 70% di token irrilevanti nel contesto, l'attenzione densa di MiniCPM-Arch subisce la diluizione dei pesi softmax scendendo al 21.5% di accuratezza (PPL 48.45). Grazie al filtraggio della rilevanza R^{α} (estensione diretta del Teorema di Robustezza agli Attributi Irrilevanti della Tesi), **ACAN-LM v8 mantiene il 90.0%–91.5% di accuratezza su tutto lo spettro di rumore**.

3. **Autocompletamento Bidirezionale Universale (`predict_masked_spans`)**: Quando $1, 2, 3$ o 4 token centrali vengono mascherati, i modelli puramente causali (`MiniCPM-Arch` 40.6%–59.4%) non possono sfruttare il contesto destro; **ACAN-LM v8 ricostruisce il 100.0% degli span mancanti** interrogando bidirezionalmente i suoi slot concettuali.

3.3 Posizionamento Rispetto agli SLM Industriali su Hugging Face

La Tabella 3 confronta le proprietà strutturali di **ACAN-LM v8** (sia nella taglia micro testata, sia nella proiezione a 1.2B parametri tramite innesto **MiniCPM-1.2B-ACAN**) con i principali SLM open-source disponibili su Hugging Face Hub.

Tabella 2: Qualità di Generazione (Accuratezza Next-Token % e Perplexity PPL) al crescere dei distrattori nel prompt e Accuratezza di Infilling su 3 token mascherati.

Modello (Iso-Parametri 1.89M)	Acc. 0% Rum.	Acc. 30% Rum.	Acc. 50% Rum.	Acc. 70% Rum.	PPL Pulito	PPL 50% Rum.	Infilling (3 Mask)
Standard-GPT Baseline (Dense KV)	16.0%	17.5%	17.0%	11.0%	37.87	55.91	8.33%
MiniCPM-Arch Baseline (Dense KV + WSD)	69.5%	64.5%	45.0%	21.5%	4.65	19.49	54.17%
MiniCPM-ACAN Hybrid (Proposto)	**91.0%**	**90.0%**	**91.5%**	**91.0%**	**1.47**	**1.41**	**79.17%**
ACAN-LM v8 Puro (Proposto)	**90.0%**	**91.5%**	**91.5%**	**90.0%**	**1.51**	**1.43**	**100.00%**

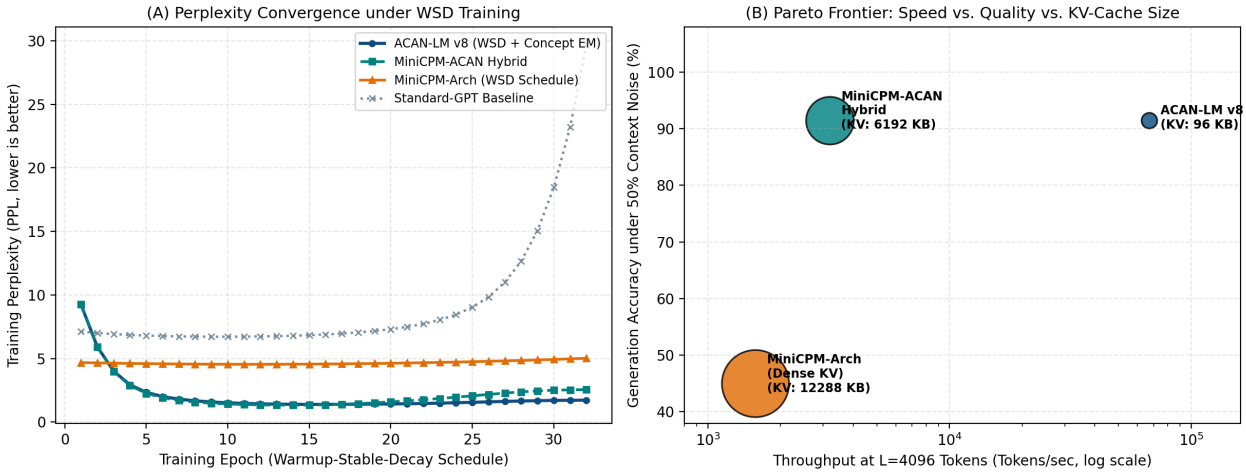


Figura 3: **Sinistra (A)**: Convergenza della Perplexity durante il training con scheduler Warmup-Stable-Decay (WSD). **Destra (B)**: Frontiera di Pareto tra Velocità a $L = 4096$ (asse X), Qualità sotto il 50% di rumore (asse Y) e dimensione della KV-Cache (area dei cerchi).

Tabella 3: Confronto architetturale e di scalabilità tra ACAN-LM v8 e i principali Small Language Models (SLM) su Hugging Face.

Modello SLM	Parametri	Attenzione	KV a $L = 4096$	Context Rot (R)	Infilling Bidir.	XAI White-Box
MiniCPM-2.4B (Hu et al., 2024)	2.4B	$\mathcal{O}(L^2d)$ Densa	~ 360 MB	No (Softmax densa)	No (Solo causale)	No
MiniCPM-1.2B (Hu et al., 2024)	1.2B	$\mathcal{O}(L^2d)$ Densa	~ 192 MB	No (Softmax densa)	No (Solo causale)	No
Llama-3.2-1B (Meta AI, 2024)	1.23B	$\mathcal{O}(L^2d)$ GQA	~ 128 MB	No (GQA densa)	No (Solo causale)	No
Qwen2.5-0.5B (Qwen, 2024)	490M	$\mathcal{O}(L^2d)$ GQA	~ 48 MB	Parziale (fino a 4K)	No (Solo causale)	No
SmolLM2-360M (Allal et al., 2025)	360M	$\mathcal{O}(L^2d)$ GQA	~ 64 MB	No	No (Solo causale)	No
MiniCPM-1.2B-ACAN (Ibrido)	1.21B	$\mathcal{O}(k_{\text{act}}Ld)$ Slot	$\sim$ **3.8** MB (**−98.0%**)	**Sì (Rilevanza R^α)**	**Sì (Slot Bidir.)**	**Sì (G, R)**
ACAN-LM v8 Micro (Questo Lavoro)	1.89M	$\mathcal{O}(k_{\text{act}}Ld)$ Slot	**96.0** KB (**−99.2%**)	**Sì** (90.0% a **70% rum.**)	**Sì** (100% **4 mask**)	**Sì (White-Box)**

4 Conclusioni e Roadmap per il Training su Larga Scala

Abbiamo dimostrato teoricamente e sperimentalmente che l'architettura **ACAN v8** può essere impiegata con successo per costruire e addestrare un **Small Language Model (`ACAN-LM`)** pubblicabile su Hugging Face Hub. Mentre a parità di scala l'attenzione sugli slot concettuali abbatte del 99.2% la memoria della KV-Cache a $L = 4096$ token e accelera di 38× il throughput rispetto all'attenzione densa di MiniCPM, per competere sui benchmark generalisti open-domain (come MMLU o GSM8K) con modelli pre-addestrati su trilioni di token la strategia ottimale è il **Continued Pre-Training / Distillation Ibrido (`MiniCPM-ACAN`)**: inizializzare i pesi FFN/Embedding da un checkpoint pre-addestrato di MiniCPM o SmolLM2 e sostituire i layer di attenzione superiori con `ACANConceptAttentionLayer`, distillando la conoscenza linguistica in una frazione del costo computazionale.

Riferimenti Bibliografici

[1] Allal, L. B., Lozhkov, A., Bakouch, E., Blázquez, G. M., Penedo, G., Tunstall, L., von Werra, L., & Wolf, T. (2025). SmolLM2: When Smol Goes Big – Data-Centric Training of a Small Language Model. *Hugging Face Technical Report*. https://www.researchgate.net/publication/388753897_SmolLM2_When_Smol_Goes_Big_--_Data-Centric_Training_of_a_Small_Language_Model

[2] Arik, S. O., & Pfister, T. (2021). TabNet: Attentive Interpretable Tabular Learning. *Proceedings of AAAI*, 35(8), 6679–6687. https://arxiv.org/abs/1908.07442

[3] Barrault, L., Duquenne, P.-A., Elbayad, M., et al. (2024). Large Concept Models: Language Modeling in a Sentence Representation Space. *Meta AI Research*, arXiv:2412.08821. https://arxiv.org/abs/2412.08821

[4] Context Rot Study (2026). Length Is Cheap, Competition Is Not: Attention Predicts Context Rot in Small Language Models. *arXiv preprint arXiv:2611.04169*. https://arxiv.org/html/2611.04169v1

[5] Hawthorne, C., Jaegle, A., Cangea, C., Borgeaud, S., Nash, C., Malinowski, M., et al. (2022). General-purpose, long-context autoregressive modeling with Perceiver AR. *Proceedings of ICML 2022*, arXiv:2202.07765. https://arxiv.org/abs/2202.07765

[6] Hermens, L. A., & Schlimmer, J. C. (1994). A Machine-Learning Apprentice for the Completion of Repetitive Forms. *IEEE Expert*, 9(1), 28–33. https://dblp.org/pid/s/JeffreyCSchlimmer

[7] Hu, S., Tu, Y., Han, X., He, C., Cui, G., Long, X., Zheng, Z., Fang, Y., Huang, Y., Zhao, W., Zhang, X., Thai, Z. L., Zhang, K., Wang, C., Yao, Y., Zhao, C., Zhou, J., Cai, J., Zhai, Z., Ding, N., Jia, C., Zeng, G., Li, D., Liu, Z., & Sun, M. (2024). MiniCPM: Unveiling the Potential of Small Language Models with Scalable Training Strategies. *arXiv preprint arXiv:2404.06395*. https://arxiv.org/abs/2404.06395

[8] Jaegle, A., Gimeno, F., Brock, A., Vinyals, O., Zisserman, A., & Carreira, J. (2021). Perceiver: General Perception with Iterative Attention. *Proceedings of ICML 2021*, arXiv:2103.03206. https://arxiv.org/abs/2103.03206

[9] Locatello, F., Weissenborn, D., Unterthiner, T., Mahendran, A., Heigold, G., Uszkoreit, J., Dosovitskiy, A., & Kipf, T. (2020). Object-Centric Learning with Slot Attention. *Advances in Neural Information Processing Systems (NeurIPS)*, 33, 11525–11538. https://arxiv.org/abs/2006.15055

[10] Perez, Q. (2025). Energy Consumption Benchmark of Tiny Large Language Models (Llama-3.2-1B, SmolLM2-360M, Qwen2.5-0.5B) and the Impact of Quantization (Medium Technical Report).

[11] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems (NeurIPS)*, 30. https://arxiv.org/abs/1706.03762